Содержание

- 1. Классификация задач предсказания
- 2. Проблема ML и DL подхода в задачах прогнозирования временных рядов
- 3. Алгоритм действий перед решением задачи
- 4. Где место ML, DL в домене?

Классификация задач предсказания

- По формату входных и выходных данных
- По наличию эндогенных и экзогенных данных
- По наличию тривиального и не тривиального паттерна
- По размерности ряда многомерные и одномерные
- По количеству точек, которые нужно предсказать

Входные и выходные данные

Размерность вход и размерность выхода

Отвечаем на вопрос - сколько выходных точек по скольки входным мы будем учиться предсказывать

- 1) Классический подход n входных, 1 выходная Предсказание на несколько точек вперед моделируется только подходом out-of-sample
- 2) Supervised + DL подход n входных, m выходных Предсказание на несколько точек впредь моделируется как out-of-sample подходом, так и нативно

По наличию эндогенных и экзогенных данных

Эндогенные данные - зависят от других параметров системы

Экзогенные данные - внешние по отношению к системе

Работа с экзогенными данными ограничена в классическом подходе

По наличию или отсутствию тривиального паттерна

Назовем ряд с тривиальным паттерном такой ряд, который не имеющие сезонности или цикличности

Ряды с тривиальным паттерном как правило не имеет смысл предсказывать ML или DL подходом

Пример - индекс Доу-Джонса, sin(t), y(t) = const, белый шум

По размерности ряда

Сами эндогенные данные могут быть представлены несколькими измеряемыми компонентами

Пример - N датчиков одной системы, снимаемых во времени

По количеству точек предсказания

- 1) One step ahead Как правило удовлетворительные данные можно получить любой моделью, однако для эндогенных одномерных данных классические подходы немного опережают в качестве.
- 2) Multistep ahead Хорошие предсказания для эндогенных данных как правило получаются только классическими подходами

Проблема ML и DL для time series

По результатам большого количества тестов была показана неэффективность ML и DL подхода для большинства типичных задач прогнозирования*

В частности:

- 1) Прогнозирование одномерных эндогенных рядов на одну и несколько точек вперед.
- 2) Прогнозирование эндогенных многомерных рядов "из коробки".

^{*} https://machinelearningmastery.com/findings-comparing-classical-and-machine-learning-methods-for-time-series-forecasting/

Возможный ответ на вопрос, почему так просходит?

1) Для рядов с короткой историей как правило недостаточно данных.

ML модель либо переобучается, либо не может выявить закономерность.

Возможный ответ на вопрос, почему так просходит?

2) Для рядов с тривиальным паттерном, как правило существует более простая модель, оптимальность которой доказана математически.

Так, например, для рядов случайного блуждания лучшим прогнозом будет наивное.

Для белого шума $y(t) \sim (\mu, \sigma^2)$, матожидание μ .

Возможный ответ на вопрос, почему так просходит?

Для всех остальных рядов:

Дело в том, что классический подход предполагает работу со стационарными рядами, для которых по теореме Вольда может быть математически найдена наилучшая модель прогнозирования.

Операция приведения к стационарному виду - это довольно сложное умение, требующее определённой интуиции эксперта, которую на данном этапе развития машинного обучения еще не представляется возможным автоматизировать.

Алгоритм действий

- 1) Выбрать подходящую модель
- 2) Выбрать метрику сравнения
- 3) Построить baseline модель
- 4) Провалидировать по метрике сравнения вашу модель с валидируемой

Выбор модели

Чтобы выбрать нужную модель, вы должны ответить на следующие вопросы

- 1) Какова размерность входных и выходных данных?
- 2) Многомерный или одномерный ряд мы предсказываем?
- 3) Есть ли у нас дополнительные экзогенные признаки?
- 4) Есть ли нетривиальный паттерн?
- 5) На сколько точек вперед нужно сделать предсказание?

Выбор метрики сравнения

MAE, RMSE, MAPE - подойдут любые

Однако удобно использовать MASE

Построение baseline модели

ARIMA, наивное предсказание, скользящие статистики вроде модель Хольта-Винтерса

- 1) Если при выборе модели вы получили задачу предсказания с одной точкой выходных данных, эндогенный одномерный ряд с нетривиальным паттерном, скорее всего вам нужен классический авторегрессионный подход (arima).
- 2) Если при выборе модели вы предсказываете ряд с тривиальным паттерном, скорее всего вам нужные простые статистические модели. Модель взвешенного среднего, наивное предсказание и т.п.

3) Если при выборе модели вы получили задачу предсказания с одной точкой выходных данных, ряд с нетривиальным паттерном, большим количеством внешних признаков, и предсказанием на одну точку вперед, скорее всего вам нужен переход к supervised задаче и классические ML алгоритмы.

4) Если при выборе модели вы получили задачу предсказания многомерного ряда с одной точкой выходных данных и возможностью ручной генерации признаков, скорее всего вам будет достаточно перехода к supervised задаче и классических ML алгоритмов.

CNN умеют автоматически генерировать большое количество признаков

5) Если при выборе модели вы получили задачу предсказания многомерного ряда с одной точкой выходных данных и невозможностью ручной генерации признаков, то имеет смысл попробовать CNN.

Нейронные сети могут принимать разный формат входных и выходных данных

6) Если при выборе модели вы получили задачу предсказания ряда с вектором выходных данных, вам стоит попробовать полносвязную сеть или RNN

Нейронные сети могут принимать нефиксированный формат входных и выходных данных

7) Если при выборе модели вы получили задачу предсказания ряда с нефиксированной длиной входных или выходных данных, стоит попробовать LSTM.

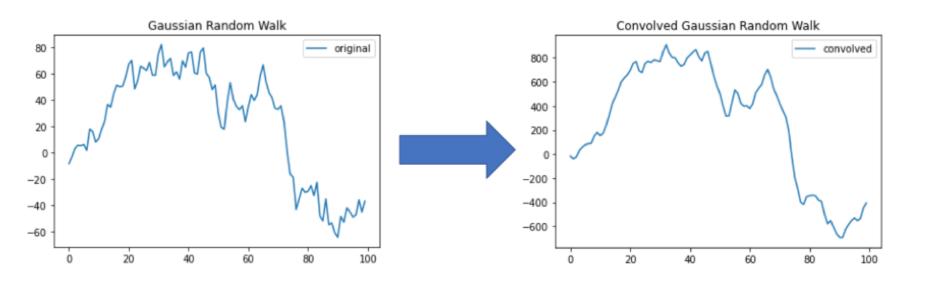
Нейронные сети могут моделировать любую нелинейную зависимость

8) Если при выборе модели вы получили задачу предсказания ряда с большим количество экзогенных признаков, у которых вы предполагаете отсутствие линейной зависимости с целевой переменной

Таким образом, в задаче прогнозирования временных рядов наибольшую пользу от использования DL можно получить в следующих задачах:

- 1) Предсказание вектора точек полносвязная сеть
- 2) Сложный feature-engineering CNN
- 3) Задача с нефиксированным форматов входных и выходных данных LSTM

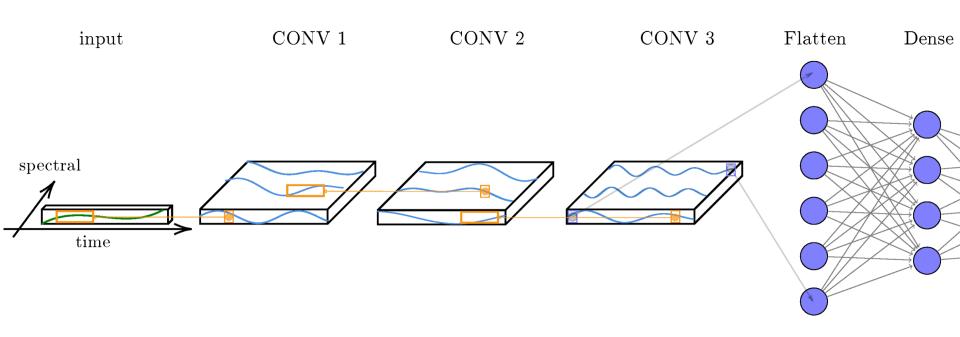
По сути это множество разнообразных фильтров по скользящему окну



Так как мы имеем дело с временной зависимостью данных, свертка идет в одном направлении: вдоль временной шкалы.

Поэтому используется Conv1D слои.

Одномерный случай



Многомерный случай

